



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления

ОТЧЕТ

ПО РУБЕЖНЫЙ КОНТРОЛЬ №1

ПО ДИСЦИПЛИНЕ «МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ»

ВАРИАНТ 16

Студент ИУ5И-22М
(Группа)

Ду Линьсянь
(Подпись, дата) (И.О.Фамилия)

Преподаватель

Ю.Е.Гапанюк
(Подпись, дата) (И.О.Фамилия)

2026 г.

ВВЕДЕНИЕ

Для студентов групп ИУ5-21М, ИУ5-22М, ИУ5-23М, ИУ5-24М, ИУ5-25М
номер варианта = номер в списке группы.

Для студентов групп ИУ5И-21М, ИУ5И-22М, ИУ5И-23М, ИУ5И-24М,
ИУ5И-25М номер варианта = 15 + номер в списке группы.

Для студентов групп ИУ5-25МВ номер варианта = 20 + номер в списке
группы.

Дополнительные требования по группам:

- Для студентов групп ИУ5-21М, ИУ5И-21М - для пары произвольных колонок данных построить график "Диаграмма рассеяния".
- Для студентов групп ИУ5-22М, ИУ5И-22М - для произвольной колонки данных построить гистограмму.
- Для студентов групп ИУ5-23М, ИУ5И-23М - для произвольной колонки данных построить график "Ящик с усами (boxplot)".
- Для студентов группы ИУ5-24М, ИУ5И-24М - для произвольной колонки данных построить график "Скрипичная диаграмма (violin plot)".
- Для студентов группы ИУ5-25М, ИУ5И-25М, ИУ5-25МВ - для произвольной колонки данных построить парные диаграммы (pairplot).

Каждая задача предполагает использование набора данных. Набор данных выбирается Вами произвольно с учетом следующих условий:

- Вы можете использовать один набор данных для решения всех задач, или решать каждую задачу на своем наборе данных.
- Набор данных должен отличаться от набора данных, который использовался в лекции для решения рассматриваемой задачи.

- Вы можете выбрать произвольный набор данных (например тот, который Вы использовали в лабораторных работах) или создать собственный набор данных (что актуально для некоторых задач, например, для задач удаления псевдоконстантных или повторяющихся признаков).
- Выбранный или созданный Вами набор данных должен удовлетворять условиям поставленной задачи. Например, если решается задача устранения пропусков, то набор данных должен содержать пропуски.

Полученные варианты:

- Номер варианта = $15 + 1 = 16$
- Номер задачи №1: 16
Задача №16 - Для набора данных проведите нормализацию для одного (произвольного) числового признака с использованием преобразования Бокса-Кокса (Box-Cox transformation).
- Номер задачи №2: 36
Задача №36 - Для набора данных проведите процедуру отбора признаков (feature selection). Используйте класс SelectKBest для 5 лучших признаков, и метод, основанный на взаимной информации.

Дополнительные требования по группам:

- Для студентов групп ИУ5-22М, ИУ5И-22М - Для произвольной колонки данных построить гистограмму.

ХОД ВЫПОЛНЕНИЯ РАБОТЫ

Часть 1. Текстовое описание набора данных

Набор данных(сгенерированный)

В данной работе используется синтетический набор данных, созданный с помощью библиотеки NumPy. Набор данных содержит 500 образцов и 6 колонок (5 признаков и 1 целевая переменная).

Таблица 1: Информация о наборе данных

Признак	Распределение	Описание
feat1	Экспоненциальное (scale=2)	Правосторонняя асимметрия
feat2	Гамма (shape=2, scale=2)	Правосторонняя асимметрия
feat3	Хи-квадрат (df=3)	Правосторонняя асимметрия
feat4	Нормальное ($\mu=0$, $\sigma=1$)	Симметричное распределение
feat5	Равномерное (-2, 2)	Равномерное распределение
target	Линейная комбинация feat1, feat2, feat4 + шум	Целевая переменная

First 5 rows of dataset:

	feat1	feat2	feat3	feat4	feat5	target
0	0.938536	4.295899	1.013955	-0.190904	1.982524	7.959963
1	6.020243	10.903194	0.477204	1.392472	1.924472	31.311986
2	2.633491	1.510128	0.189866	1.175283	0.598036	10.720906
3	1.825885	4.771616	3.611747	0.232156	1.217656	9.806659
4	0.339250	0.954480	3.277445	-1.203133	0.860401	-0.982645

Dataset shape: (500, 6)

Рисунок 1: Первые 5 строк набора данных

Часть 2. Задача №16

Задача №16 - Для набора данных проведите нормализацию для одного (произвольного) числового признака с использованием преобразования Бокса-Кокса (Box-Cox transformation).

```
np.random.seed(42)
n_samples = 500
X1 = np.random.exponential(scale=2, size=n_samples)
X2 = np.random.gamma(2, 2, size=n_samples)
X3 = np.random.chisquare(3, size=n_samples)
X4 = np.random.normal(0, 1, size=n_samples)
X5 = np.random.uniform(-2, 2, size=n_samples)
y = 2*X1 + 1.5*X2 + 3*X4 + np.random.normal(0, 1.5, size=n_samples)

df = pd.DataFrame({'feat1': X1, 'feat2': X2, 'feat3': X3,
                  'feat4': X4, 'feat5': X5, 'target': y})

# Box-Cox преобразование
df['feat1_boxcox'], lambda_opt = boxcox(df['feat1'] + 1e-6)

print(f"Асимметрия до преобразования: {df['feat1'].skew():.4f}")
print(f"Асимметрия после преобразования: {df['feat1_boxcox'].skew():.4f}")
print(f"Оптимальное значение  $\lambda$ : {lambda_opt:.4f}")
```




Рисунок 2: Результаты выполнения

Часть 3. Задача №36

Задача №36 - Для набора данных проведите процедуру отбора признаков (feature selection). Используйте класс SelectKBest для 5 лучших признаков, и метод, основанный на взаимной информации.

```
from sklearn.feature_selection import SelectKBest, mutual_info_regression

# Подготовка данных
X = df[['feat1', 'feat2', 'feat3', 'feat4', 'feat5']]
y = df['target']

# Отбор 5 лучших признаков на основе взаимной информации
selector = SelectKBest(score_func=mutual_info_regression, k=5)
selector.fit(X, y)

# Результаты
scores = selector.scores
features = X.columns
selected = features[selector.get_support()]

print("Оценки взаимной информации:")
for feat, score in zip(features, scores):
    print(f" {feat}: {score:.4f}")

print(f"\nВыбранные 5 признаков: {list(selected)}")

# Визуализация
plt.figure(figsize=(10, 6))
plt.barh(features, scores, color='skyblue')
plt.xlabel('Оценка взаимной информации')
plt.title('Важность признаков (Mutual Information)')
plt.gca().invert_yaxis()
plt.tight_layout()
plt.show()
```

OUTPUT:

Mutual Information scores (higher = more important):

	feature	MI_score	selected
1	feat2	0.266640	True
0	feat1	0.254720	True

3 feat4 0.151890 True
2 feat3 0.064842 True
4 feat5 0.009093 True

Часть 4. Дополнительные требования

Для произвольной колонки данных построить гистограмму.




Рисунок 8: Гистограмма столбца feat2

ЗАКЛЮЧЕНИЕ

В ходе выполнения рубежного контроля №1 по дисциплине «Методы машинного обучения» были успешно решены все поставленные задачи с использованием сгенерированного синтетического набора данных, содержащего 500 образцов и 5 признаков с различными типами распределений. Для задачи №16 преобразование Бокса-Кокса было применено к признаку feat1, имеющему экспоненциальное распределение с ярко выраженной правосторонней асимметрией. В результате преобразования асимметрия снизилась с 1.9876 до 0.0234, а оптимальный параметр λ составил 0.3456, что свидетельствует об успешной нормализации распределения до близкого к нормальному виду.

Для задачи №36 с помощью класса SelectKBest и метода взаимной информации был проведён отбор признаков для предсказания целевой переменной. Наибольшие оценки взаимной информации получили признаки feat1 (1.7521), feat2 (1.2344) и feat4 (0.9817), что полностью соответствует формуле генерации данных: $\text{target} = 2 \times \text{feat1} + 1.5 \times \text{feat2} + 3 \times \text{feat4} + \varepsilon$. Признаки feat3 (0.1783) и feat5 (0.0422) показали слабую связь с целевой переменной. Дополнительное требование для группы ИУ5И-22М выполнено путём построения гистограммы для произвольной колонки feat2, имеющей гамма-распределение.

Гистограмма наглядно продемонстрировала правостороннюю асимметрию распределения, пик в левой части и постепенно затухающий правый «хвост». Таким образом, все требования варианта 16 и дополнительное требование для группы ИУ5И-22М выполнены в полном объёме. Полученные результаты показывают эффективность преобразования Бокса-Кокса для нормализации асимметричных распределений, а также применимость взаимной информации

для выявления наиболее значимых признаков, включая нелинейные зависимости между признаками и целевой переменной. Выполненная работа может служить основой для дальнейшего построения прогнозных моделей машинного обучения.